


이 게임은 두 층위에서 AI를 쓴다. 게임 안에는 플레이어의 로그를 읽고 다음 웨이브를 설계하는 AI 디렉터가 있고, 게임을 만드는 과정 자체도 스펙 → 플랜 → 구현 → 리뷰로 이어지는 AI 파이프라인으로 진행했다. 이 문서는 두 층을 순서대로 설명한다 — [1층] 게임 안의 AI, [2층] 개발에 쓴 AI. 마지막에 외부 에셋·오픈소스 출처를 정리한다.

[1층] 게임 안의 AI — 디렉터

1.1 아키텍처

디렉터는 게임을 자유롭게 조작하지 않는다. 매 웨이브 종료 시 정해진 파이프라인을 한 번 통과해 다음 웨이브의 디렉티브 하나를 만들어낼 뿐이다. 정상 경로와 장애 경로 모두 같은 엔진 실행부로 합류한다.



엔진은 그 디렉티브가 LLM에서 왔는지 폴백 बैं크에서 왔는지 모른다. 계약은 `src/contracts/directive.ts` 하나(zod 스키마)이고, Edge Function은 별도 번들이라 소스를 import할 수 없어 같은 스키마의 수동 사본을 JSON Schema 형식으로 들고 있다 — 계약을 바꾸면 두 곳을 함께 고쳐야 한다.

1.2 입출력 계약

director-client가 웨이브 종료마다 집계해 보내는 플레이 로그:

```
{
  "wave": 2, "clearTimeSec": 34.2, "hpLost": 2,
  "damageSources": {"chaser": 1, "shooter": 1},
  "movement": {"quadrantTime": {"NW": 0.4, "NE": 0.1, "SW": 0.4, "SE": 0.1},
    "wallHugRatio": 0.55, "dashCount": 6},
  "combat": {"kills": {"chaser": 12, "shooter": 3, "splitter": 2}, "accuracy": 0.61},
  "upgrades": ["DAMAGE_UP", "MOVE_SPEED_UP"],
  "prevMutations": ["FOG"]
}
```

디렉터가 돌려주는 디렉티브 — 자유 텍스트가 아니라 이 네 필드로 제한된 JSON:

```
{
  "composition": [
    { "type": "chaser|shooter|splitter", "count": 1, "spawn": "N|S|E|W|RING|Pincer|BEHIND", "elite": false }
  ],
  "mutation": "NONE|LAVA_LEFT|LAVA_RIGHT|FOG|SPEED_SURGE|SHRINK_ARENA|SPAWN_STORM",
  "taunt": "60자 이내 — 로그의 실제 습관 1개 지목",
  "intent": "100자 이내 — 설계 의도"
}
```

1.3 시스템 프롬프트 전문

Edge Function이 Claude Haiku 4.5에 보내는 시스템 프롬프트 두 개를 그대로 옮긴다. 하나는 매 웨이브의 디렉티브 생성용, 하나는 런 종료 시 리포트 생성용이다.

디렉티브 생성 (mode: 'directive')

너는 아케이드 게임의 'AI 디렉터'다. 플레이어의 웨이브 로그를 읽고 다음 웨이브를 설계한다.

규칙:

- composition 총 비용(chaser 1, shooter 2, splitter 2, elite는 $\times 3$)은 예산 이하로. 예산은 사용자 메시지에 준다.
- taunt는 한국어 60자 이내. 반드시 로그에서 실제로 관찰되는 습관 하나를 꼭 집어 지목하라(예: 벽 붙기 wallHugRatio, 특정 사보면 체류, 낮은 명중률, 대시 남용, 특정 적에게 반복 피격, 업그레이드 성향). 그리고 설계가 그 습관을 실제로 공략해야 한다.
- 해석 규칙: hpLost가 damageSources 합보다 크면 그 차이는 지형 피해(용암 존·축소 경계)다 - 지형에 자주 타는 플레이어에게는 그 습관을 지목할 수 있다.
- 직전 mutation과 같은 것은 고르지 마라.
- 어렵지만 이길 수 있게: 플레이어가 고전한 요소는 유지하되 물량으로 압살하지 마라.
- intent는 설계 의도 100자 이내.

사용자 메시지: 웨이브 $\${wave}$ 설계. 예산: $\${budget}$. 직전 mutation: $\${prevMutation}$. + 플레이 로그 JSON.

리포트 생성 (mode: 'report')

너는 게임의 AI 디렉터다. 방금 끝난 판의 전체 로그를 보고, 플레이어의 스타일을 분석하는 리포트를 한국어 400자 내외로 써라. 마지막 줄에 "칭호: <4~8자 칭호>" 형식으로 칭호를 붙여라. 관찰된 사실만 근거로, 디렉터의 시점(1인칭)으로, 패배시켰다면 여유롭게, 패배했다면 인정하며.

호출 파라미터: model `claude-haiku-4-5` max_tokens 500(디렉티브)/700(리포트). 디렉티브 호출은 `output_config: { format: { type: 'json_schema', schema: DIRECTIVE_JSON_SCHEMA } }`로 API 레벨에서 출력 스키마를 강제한다 — 응답 텍스트를 파싱해 JSON을 추출하는 방식이 아니라, 모델이 스키마에 맞는 JSON만 내도록 디코딩 단계에서 제약한다.

1.4 권한 경계 설계

디렉터에게 준 것은 코드가 아니라 어휘다. composition·mutation·taunt·intent 네 필드 바깥으로는 어떤 값도 낼 수 없고, 그 안에서도 API 스키마(서버)와 zod(클라이언트) 두 번을 거쳐야 엔진에 닿는다. 이렇게 설계한 이유는 하나다 — 심사자가 이 게임을 직접 플레이하는 동안 LLM 쪽에서 무슨 일이 나도 게임이 멈추면 안 된다.

층위	규칙
스키마	zod 검증 — 필드 누락·enum 밖 값·문자열 길이 초과 시 거부
예산	<code>budgetFor(wave) = 8 + wave$\times$4 + max(0, wave-5)$\times$12</code> 이하만 허용(비용: chaser 1·shooter 2·splitter 2, elite $\times 3$). 난이도 곡선을 LLM이 깨뜨릴 수 없다
반복	직전 mutation과 동일하면 검증 계층이 NONE으로 강제 교체
시간	4초 초과·네트워크 오류·검증 실패 → 사전 제작 풀백 बैं크(웨이브별 3종 $\times 6$ + 오프닝 1)에서 무작위 선택. 대사도 बैं크에 포함돼 있어 플레이어는 풀백 여부를 알 수 없다

이 경계는 실측으로 확인했다. 장애 경로(네트워크 오류·타임아웃·스키마 위반)는 유닛 테스트 4건에 더해, 배포 전 상태(프록시 URL 없음)에서 오프닝부터 웨이브7 WIN까지 전 구간을 풀백만으로 완주한 라이브 런으로 검증했다 — 웨이브 전환 중 정지는 없었다. 예산 규칙은 유닛 테스트 8건과, 풀백 बैं크에 들어있는 디렉티브 19개(오프닝 1 + 웨이브별 3종 $\times 6$) 전수 검증으로 확인했다. 적 58기가 동시에 활성화된 상태에서 프레임당 처리 비용은 평균 0.145ms(60fps 예산 16.7ms 대비 약 115배 여유)로, 디렉터가 물량을 늘려도 프레임이 무너질 여지는 작다. 세션당 호출 20회·일일 500회 캡은 경계값 시뮬레이션으로 확인했다(21회째부터 거부, 501회째부터 거부).

설계 사례 — 계약을 바꾸지 않고 프롬프트로 푼 문제

지형 피해 해석 규칙이 이 원칙을 보여준다. 텔레메트리는 적 타입별 피해(damageSources)만 집계하고 용암·축소 지형에 의한 피해는 별도 필드가 없다 — 계약을 바꾸면 엔진·검증기·뱅크 19개 항목을 전부 다시 맞춰야 한다. 대신 시스템 프롬프트에 해석 규칙 한 줄을 추가했다:

`hpLost -  $\Sigma$  damageSources = 지형 피해`. 계약은 그대로 두고, 디렉터가 로그에서 지형 피해를 스스로 읽어내게 했다.

[2층] 개발에 쓴 AI — AI-DLC 파이프라인

2.1 파이프라인 구조

게임 코드도 같은 원칙으로 만들었다 — AI에게 자유를 주는 대신 단계마다 문서로 경계를 그었다. 흐름은 스펙(frozen) → 플랜(승인) → 태스크별 구현 에이전트 → 독립 리뷰 에이전트 → fix 라운드 → 스코프 재리뷰 → 다음 태스크다. 구현 에이전트와 리뷰 에이전트는 분리돼 있다 — 코드를 쓴 에이전트가 자기 코드를 검사하지 않는다. 모든 태스크는 커밋 전에 하네스 (`scripts/ai_harness.sh --fast`: tsc+lint+유닛, `---full`: +빌드)를 통과해야 하고, 통과 여부는 `HARNESS RESULT: PASS|FAIL` 한 줄로 확정된다. 계약은 `src/contracts/directive.ts` 하나가 SSOT다 — 엔진은 이 타입만 알고 디렉터 내부(LLM인지 뱅크인지)를 모른다.

2.2 핵심 서사 — 코드보다 계획을 먼저 고친다

Never Vibe Code 원칙: 구현 중 계획의 결함이 드러나면 코드부터 고치지 않는다. 계획·스펙을 먼저 고쳐 커밋한 뒤에야 구현을 재개한다.

`plan:` / `spec:` / `docs:` 커밋이 그 기록이고, 각각 뒤따르는 구현 커밋과 짝을 이룬다.

발견	계획 커밋	구현 커밋	무엇이 잘못됐었나
예산 곡선 ↔ 피날레 콘텐츠 모순	<code>a2cca53</code>	<code>f250404</code>	계획의 예산식이 계획 자신의 웨이브 6~7 बैंक 콘텐츠들 거부
텔레메트리 픽스처가 두 지표를 판별 못함	<code>8c8acf6</code>	<code>397fb59</code>	벽면 체류·사분면 체류가 항상 같은 값이 되는 픽스처
원격 QA 제약(백그라운드 탭 rAF 정지)	<code>498c28e</code>	(Task 8 구현)	검증 수단 부재를 계획에 반영해 dev QA 혹 추가
지형 피해가 적 타입별 집계에 안 잡힘	<code>2bdc965</code>	(Task 7 프록시)	계약을 바꾸는 대신 프롬프트에 해석 규칙 추가
Phaser 버전 표기 오류(3→4)	<code>e15f9dc</code>	—	스펙·플랜의 사실 오류를 실측 후 정정

첫 사례 — 이 방식이 실제로 작동한다는 증거

웨이브가 진행될수록 예산이 커지도록 짠 곡선이, 같은 계획서가 정해둔 웨이브 6~7 बैंक 콘텐츠보다 낮았다 — 계획대로면 사전 제작해 둔 후반 웨이브 디렉티브를 배치할 예산이 부족했다. 구현 에이전트는 콘텐츠를 임의로 깎아 맞추지 않았다. 대신 정지하고 컨트롤러에게 보고했고, 컨트롤러가 계획의 예산 곡선을 개정해 커밋(`a2cca53`)한 뒤에야 구현이 재개돼 다음 커밋(`f250404`)으로 이어졌다. 구현 에이전트가 승인된 계획을 스스로 깎지 않고 멈춰 보고했다는 것 자체가 이 파이프라인의 설계다 — 코드 층위의 권한 경계(1.4절)를 개발 프로세스 층위에도 그대로 적용한 것이다.

2.3 리뷰가 잡은 실결함

태스크마다 별도의 리뷰 에이전트가 스펙 준수와 코드 품질을 판정했다. Critical-Important 지적은 fix 라운드로 처리하고 스코프 재리뷰로 달았다. 아래 7건 중 2건은 자동 테스트가 아니라 라이브 플레이 중에만 드러났다.

태스크	지적	성격
4	픽스처가 두 지표를 판별 못함	테스트가 검증하지 못하는 상태를 검증한다고 착각
5	엘리트 이속 상승 미구현	스펙 항목이 브리프 전달 과정에서 누락
6	인터벌 잔여 탄환이 마감된 웨이브 로그를 오염	라이브 레퍼런스·로테이션 타이밍
6	SPAWN_STORM 빈 배치로 클리어 최대 8초 지연	현 콘텐츠엔 미발현, LLM 디렉티브에서 발현 가능
7	Edge Function 스키마 수동 사본 동기화 의무 미문서화	다음 세션이 알 수 없는 암묵지
8	타이핑 스킵 후 잔여 타이머가 확정 대사를 덮어씀	라이브 플레이로만 발견(구현자 자체 발견)
9	인터벌 대기 중 사망 시 웨이브 로그 중복 기록	라이브 플레이로만 발견(구현자 자체 발견)

2.4 규모

이 문서를 쓰는 시점(2026-08-05) 기준 실측치다. 제출 직전 최종 재산출 대상. 커밋 33개, TypeScript 26파일 2,824줄, 유닛 테스트 33개(6개 파일 전체 통과). 커밋 유형 분포: feat 10 · plan 5 · fix 7 · spec 3 · docs 5 · test 1 · chore 2. `plan` 커밋이 별도 카테고리 5건 존재한다는 사실 자

체가 이 파이프라인의 증거다 — 코드를 고치기 전에 계획 문서를 고친 기록이 커밋 히스토리에 그대로 남아 있다.

2.5 원격 QA 기법

자동화 브라우저는 백그라운드 탭에서 requestAnimationFrame이 스로틀돼 게임 시간이 흐르지 않는다 — 인터벌 타이머도, SPAWN_STORM 같은 예약 스폰도 실시간 대기로는 진행되지 않는다. `window.__game.loop.step(t)`를 고정 간격으로 직접 호출해 프레임을 결정론적으로 전진시키는 방식(`__pump(n)`)으로 우회했다. 이 기법으로 7웨이브 완주, 승/패 양 엔딩, 재시작 초기화를 원격으로 검증했다.

[공통] 외부 에셋 / 오픈소스 출처

이미지·사운드 파일은 리포지토리에 하나도 없다(png·jpg·svg·mp3·wav·ogg·폰트 파일 검색 결과 0건). 모든 그래픽은 Phaser의 `Graphics.generateTexture`로 런타임에 생성하고, 모든 효과음은 zzfx로 절차 생성한다. 외부 에셋 라이선스 리스크는 0이다.

패키지	버전	라이선스	역할
phaser	4.2.1	MIT	게임 엔진
zod	4.4.3	MIT	디렉티브 스키마 검증
zzfx	1.3.2	MIT	절차적 효과음 생성
typescript	7.0.2	Apache-2.0	개발 도구 — 타입체크·빌드(dev)
@types/node	26.1.2	MIT	타입 정의(dev)
vite	8.2.0	MIT	빌드·개발 서버(dev)
vitest	4.1.10	MIT	유닛 테스트 러너(dev)
@anthropic-ai/sdk	0.115.0(고정)*	MIT	Edge Function의 Claude API 클라이언트

* Edge Function은 Deno 런타임에서 `npm:@anthropic-ai/sdk` 스펙 임포트를 쓴다 — 프론트엔드 의존성처럼 lockfile로 관리되지 않아, 심사 기간(제출 8/10 ~ 본선 9/4~6) 중 상위 버전의 breaking change가 프록시를 깨뜨릴 위험을 막기 위해 정확 버전 (`npm:@anthropic-ai/sdk@0.115.0`)으로 고정했다.

AI 도구 사용 내역 — 개발 전 과정에서 쓴 AI 도구는 Claude Code(Claude Fable 5 / Opus 5)다. 스펙·플랜 수립, 구현·리뷰 에이전트 오케스트레이션에 사용했다. 게임 런타임에서 실제로 플레이어를 상대하는 AI는 Claude Haiku 4.5(Anthropic API, structured output)다.